



Relatório Final – Classificação de Smartphones Utilizando K-Nearest Neighbors (KNN)

Integrantes:

David Fernando de Moraes Leitão - 12631713

Felipe Panini da Silva - 12631337

Manuela Caceres Nascimento - 12632100

Patrícia Andrade da Silva - 11513882

Paulo Vitor Sando - 10722709

1. Contextualização e Motivação da Escolha do Dataset

O dataset selecionado é composto por informações técnicas de smartphones, incluindo características relacionadas ao hardware, conectividade, desempenho, memória, bateria, câmeras e dimensões físicas dos aparelhos. Cada registro representa um modelo de smartphone com especificações próprias, permitindo analisar como essas características influenciam o valor de mercado dos dispositivos.

A escolha desse conjunto de dados foi motivada pela sua adequação a problemas de classificação supervisionada. O dataset possui uma variável alvo denominada `price_range`, responsável por classificar os smartphones em quatro faixas de preço diferentes. Dessa forma, é possível investigar a relação entre os atributos dos aparelhos e sua respectiva categoria de preço, o que faz com que o conjunto de dados seja apropriado para o treinamento e avaliação de modelos preditivos.

Além disso, o dataset contém predominantemente variáveis numéricas, característica que favorece a aplicação do algoritmo K-Nearest Neighbors (KNN), uma vez que esse método realiza suas previsões com base na proximidade e similaridade entre as observações por meio do cálculo de distâncias.

Outro aspecto relevante é que o conjunto de dados não contém informações pessoais ou sensíveis, permitindo a realização das análises de forma ética e sem preocupações relacionadas à privacidade dos indivíduos.

2. Análise Exploratória

Visão Geral

O dataset possui informações técnicas de smartphones e tem como objetivo classificar os aparelhos em diferentes faixas de preço por meio da variável alvo `price_range`.

Variável	Tipo de Dado	Descrição
battery_power	Númérico (Int)	Capacidade total de energia da bateria medida em mAh.
bluetooth	Binário (0/1)	Indica se o aparelho possui conectividade Bluetooth.
clock_speed	Númérico (Float)	Velocidade com que o microprocessador executa as instruções (em GHz).
dual_sim	Binário (0/1)	Indica se o celular possui suporte para dois chips (Dual SIM).
front_camera	Númérico (Int)	Resolução da câmera frontal medida em Megapixels.
four_g	Binário (0/1)	Indica se o aparelho possui suporte para rede 4G.
storage	Númérico (Int)	Memória interna/armazenamento do celular em Gigabytes.
mobile_weight	Númérico (Int)	Peso total do aparelho celular medido em gramas.
n_cores	Númérico (Int)	Quantidade de núcleos presentes no processador do aparelho.
primary_camera	Númérico (Int)	Resolução da câmera principal (traseira) medida em Megapixels.
px_height	Númérico (Int)	Altura da resolução da tela medida em pixels.
px_width	Númérico (Int)	Largura da resolução da tela medida em pixels.
ram	Númérico (Int)	Memória de Acesso Aleatório (RAM) medida em Megabytes.
sc_height	Númérico (Int)	Altura física da tela do celular medida em centímetros.
sc_width	Númérico (Int)	Largura física da tela do celular medida em centímetros.
talk_time	Númérico (Int)	Tempo máximo (em horas) que a bateria dura em uma chamada telefônica.
three_g	Binário (0/1)	Indica se o aparelho possui suporte para rede 3G.
touch_screen	Binário (0/1)	Indica se a tela do aparelho é sensível ao toque (Touch Screen).
wifi	Binário (0/1)	Indica se o aparelho possui conectividade Wi-Fi.
price_range	Previsão (0 a 3)	Variável alvo. Faixa de preço do celular (0: Baixo, 1: Médio, 2: Alto, 3: Muito Alto).

Verificação de Valores Ausentes

O dataset não apresenta valores ausentes, dispensando técnicas de imputação ou preenchimento de dados.

Verificação de Dados Duplicados

Zero Registros Duplicados

Distribuição das Classes

O dataset apresenta classes perfeitamente balanceadas, fator importante para evitar viés durante o

treinamento do modelo.

Análise das Variáveis

O dataset contém atributos relacionados às características dos smartphones, como:

capacidade da bateria (battery_power);
conectividade Bluetooth (blue);
velocidade do processador (clock_speed);
memória interna (int_memory);
memória RAM (ram);
resolução da tela (px_height e px_width);
quantidade de núcleos do processador (n_cores);
câmeras frontal e principal (fc e pc).

Essas características possuem potencial influência sobre a faixa de preço dos dispositivos.

Valores Iguais a Zero

Durante a exploração dos dados, observou-se a presença de valores iguais a zero em algumas colunas.

Exemplos:

- fc = 0 → aparelho sem câmera frontal;
- pc = 0 → aparelho sem câmera principal;
- blue = 0 → sem Bluetooth;
- four_g = 0 → sem suporte a 4G;
- wifi = 0 → sem Wi-Fi.

Conclusão:

Grande parte dos valores iguais a zero representa ausência de funcionalidades e não necessariamente erros ou inconsistências nos dados.

3. Procedimentos de preparação dos dados

Durante a etapa de preparação dos dados foram realizadas as seguintes ações:

Renomeação de colunas

Para melhorar a legibilidade do código:

Original	Novo Nome
Blue	Bluetooth
Fc	front_camera
Pc	primary_camera
int_memory	Storage
mobile_wt	mobile_weight
sc_h	sc_height
sc_w	sc_width

Remoção da coluna m_dep

Foi removida por apresentar baixa relevância para a classificação da faixa de preço quando comparada a atributos como RAM, bateria e resolução da tela.

Conclusão

A análise exploratória demonstrou que o dataset possui boa qualidade, sem valores ausentes ou registros duplicados. Além disso, as classes encontram-se perfeitamente balanceadas, favorecendo o treinamento de modelos de classificação. Durante a curadoria dos dados foram realizadas renomeações para melhorar a compreensão dos atributos e removida uma variável considerada pouco relevante. Após testes experimentais, foi realizada uma seleção de atributos visando melhorar o desempenho do algoritmo KNN.

4. Comparação entre os resultados obtidos

Resultados	Métrica	KNN Scikit-Learn (K=25)	KNN Manual (K=31)
Classe 0 (Preço Baixo)	Precision	0.84	0.82
Classe 0 (Preço Baixo)	Recall	0.88	0.82
Classe 0 (Preço Baixo)	F1-Score	0.86	0.82
Classe 1 (Preço Médio)	Precision	0.60	0.63
Classe 1 (Preço Médio)	Recall	0.59	0.55
Classe 1 (Preço Médio)	F1-Score	0.60	0.59
Classe 2 (Preço Alto)	Precision	0.59	0.52
Classe 2 (Preço Alto)	Recall	0.60	0.73
Classe 2 (Preço Alto)	F1-Score	0.59	0.61
Classe 3 (Muito Alto)	Precision	0.86	0.94
Classe 3 (Muito Alto)	Recall	0.82	0.76
Classe 3 (Muito Alto)	F1-Score	0.84	0.84
Geral / Total	Acurácia	72.25%	71.00%

Critério Técnico	KNN Scikit-Learn (KNN_Biblioteca.ipynb)	KNN Manual (KNN_Manual.ipynb)
Fórmula de Distância	Distância Euclidiana (Otimizada via C/Cython interna).	Distância Euclidiana (Construída do zero com np.sqrt e np.sum).
Estratégia de Divisão	train_test_split com estratificação (stratify=y — garante proporções exatas de classes no teste).	Embaralhamento (sample) seguido de corte seco proporcional (80% treino / 20% teste).
Normalização	Feita via objeto MinMaxScaler() importado do sklearn.	Feita manualmente calculando $(X - X.min()) / (X.max() - X.min())$.
Desempate de Votos	Algoritmos internos da biblioteca tratam empates de distância.	Utiliza o método .most_common(1) da biblioteca padrão Counter.
Velocidade / Escala	Altamente performático ideal para grandes bases de dados.	Mais lento por usar estruturas de repetição (for) explícitas em Python para calcular cada ponto.
Objetivo Didático	Focado em produtividade aplicação ágil e validação de métricas de mercado.	Perfeito para entender a matemática por trás do algoritmo de vizinhos mais próximos.

Conclusão

O presente estudo cumpriu com êxito o objetivo de analisar a aplicabilidade do algoritmo *K-Nearest Neighbors* (KNN) na classificação de faixas de preço de dispositivos móveis, confrontando uma abordagem comercial pronta (scikit-learn) com uma implementação desenvolvida do zero (manual). Os resultados experimentais consolidados permitem delinear três conclusões fundamentais:

- Validação e Equivalência Algorítmica: A implementação manual do KNN demonstrou robustez matemática e conceitual ao atingir 71,00% de acurácia. Este índice posicionou-se em estreita equivalência com os 72,25% obtidos pela biblioteca de mercado, evidenciando que a sutil variação decorre exclusivamente da técnica de partição dos dados (amostragem sequencial versus divisão estratificada) e não de inconsistências na lógica de cálculo.
- Impacto da Seleção de Atributos (*Feature Selection*): O experimento ratificou a suscetibilidade do KNN à "maldição da dimensionalidade". A inclusão de variáveis de baixa correlação com o valor de mercado (como presença de *Wi-Fi* ou *Bluetooth*) introduziu ruído nos cálculos de distância euclidiana, reduzindo a acurácia para patamares insatisfatórios (49% a 57%)[cite: 1, 2, 3]. Em contrapartida, a filtragem para 8 atributos

preditivos essenciais funcionou como o principal vetor de otimização, elevando a acurácia geral para a faixa de 73% nos melhores cenários

- Assimetria na Discretização das Classes: Observou-se um comportamento assimétrico na capacidade preditiva do modelo. Enquanto as classes extremas — Preço Baixo (0) e Muito Alto (3) — apresentaram excelente separabilidade (F1-scores de até 0,86 e 0,94), as classes intermediárias (1 e 2) revelaram-se zonas de forte sobreposição de hardware, limitando o desempenho devido à proximidade contígua dos vetores de características no espaço multidimensional

Em suma, conclui-se que o algoritmo KNN se mostra eficaz para a precificação de *smartphones*, desde que precedido por uma rigorosa etapa de engenharia e seleção de atributos. Enquanto a solução via biblioteca consolida-se como o padrão para implantações industriais devido à sua eficiência computacional e de escala, o desenvolvimento do modelo manual valida o domínio metodológico das mecânicas intrínsecas de aprendizado de máquina, atingindo o rigor acadêmico pretendido.

5. Aspectos Éticos, Sociais e de Segurança

Embora o dataset utilizado neste trabalho não contenha informações pessoais, alguns cuidados ainda são necessários durante a manipulação dos dados e a construção dos modelos.

Em relação aos aspectos éticos, é importante garantir que os dados utilizados sejam confiáveis e representem corretamente o problema estudado. Erros, inconsistências ou alterações inadequadas podem comprometer os resultados obtidos pelo modelo.

Do ponto de vista social, é importante lembrar que as previsões geradas por algoritmos não devem ser interpretadas como decisões definitivas. Os resultados dependem diretamente da qualidade dos dados utilizados no treinamento e das escolhas feitas durante o desenvolvimento do projeto, como seleção de atributos e definição dos parâmetros do modelo.

Quanto à segurança, foram realizadas verificações para identificar valores ausentes, registros duplicados e possíveis inconsistências nos dados. Além disso, foi feita uma comparação entre a implementação manual do KNN e a implementação utilizando a biblioteca scikit-learn, permitindo validar os resultados e aumentar a confiabilidade da análise.

Dessa forma, a qualidade dos dados, a transparência das etapas realizadas e a validação dos resultados foram fatores importantes para garantir maior segurança e confiabilidade ao trabalho desenvolvido.

6. Cronograma de Execução e Atribuições do Grupo

Para a execução do trabalho, o grupo realizou sete reuniões ao longo do desenvolvimento das Partes 1 e 2 do projeto. Os encontros ocorreram de forma remota, por meio do Google Meet, sempre buscando conciliar a disponibilidade de todos os integrantes. O horário mais frequente das reuniões foi das 19h às 23h.

Durante o desenvolvimento do projeto, Patrícia, Felipe e Paulo, participaram ativamente das atividades desenvolvidas de forma colaborativa, com compartilhamento de tela entre os integrantes, permitindo que todos os três acompanhassem as etapas de análise, pré-processamento dos dados e implementação

do algoritmo KNN. Dessa forma, os participantes presentes nas reuniões puderam compreender integralmente o processo de desenvolvimento do trabalho.

Após sete reuniões realizadas, Manuela e David participaram apenas da última reunião, ocasião em que foram apresentados os avanços do projeto e definidas as atividades finais.

Paulo: desenvolvimento do projeto e tratamento e manipulação dos dados;

Felipe: desenvolvimento do projeto e comparação dos resultados obtidos pelos modelos e organização do material no GitHub;

Patrícia: desenvolvimento do projeto, elaboração da apresentação final e redação do relatório;

Manuela e David: preparação e realização da apresentação oral do trabalho.

A divisão das atividades considerou a participação e a disponibilidade dos integrantes ao longo do desenvolvimento do projeto.